

Trabajo Práctico 2: Programación Dinámica para el Reino de la Tierra

Facultad de Ingeniería de la Universidad de
Buenos Aires

Teoría de Algoritmos

Cátedra Buchwald-Genender



Gómez Belis, Sofía
Padrón: 109358
email: sgomezb@fi.uba.ar

Llanos Pontaut,
Valentina
Padrón: 104413
email: vllanos@fi.uba.ar

Orsi, Tomas Fabrizio
Padrón: 109735
email: torsi@fi.uba.ar

Indice

| | | |
|----------|---|-----------|
| 1 | Análisis del problema | 2 |
| 1.1 | Descripción y objetivo | 2 |
| 1.2 | Análisis y ecuación de recurrencia | 2 |
| 2 | Complejidad algorítmica | 4 |
| 2.1 | Complejidad lectura de archivos | 4 |
| 2.2 | Complejidad algoritmo | 5 |
| 2.3 | Complejidad reconstrucción de la solución | 6 |
| 2.4 | Efecto de las variables sobre el algoritmo | 7 |
| 3 | Análisis de optimalidad ante la variabilidad de x_i y $f(j)$ | 8 |
| 4 | Ejemplos de ejecución | 10 |
| 5 | Mediciones de tiempo | 12 |
| 6 | Conclusión | 13 |

1 Análisis del problema

1.1 Descripción y objetivo

El objetivo de este trabajo práctico es implementar un algoritmo de programación dinámica para ayudar a los Dai Li, la policía secreta de la ciudad Ba Sing Se del Reino de la Tierra, en su combate contra la Nación del Fuego. Como somos sus jefes estratégicos, debemos reportarles las estrategias que deberían emplear en cada minuto del ataque con el fin de eliminar la máxima cantidad de maestros Fuego.

Afortunadamente, las mediciones sísmicas de los Dai Li nos permitieron obtener información de la cantidad de enemigos que llegan en cada minuto. Además, sabemos que la cantidad de enemigos no es acumulativa; después de cada ataque, los enemigos se retiran. Tenemos entonces, una lista de valores x_i que ilustran este hallazgo. Por otro lado, la potencia de los ataques de fisura de la policía secreta dependen de cuánto tiempo fue cargada la energía. La función monótona creciente $f(\cdot)$ indica que, si transcurrieron j minutos desde que se utilizó este ataque, entonces se podrá eliminar hasta $f(j)$ soldados enemigos. Como este valor puede ser mayor a la cantidad de maestros Fuego, en el minuto k se podrá eliminar $\min(x_k, f(j))$ soldados, perdiendo además la energía acumulada. En el primer minuto, en caso de decidir atacar, les corresponde $f(1)$ de energía.

Sabiendo la duración en minutos del ataque (n), y los valores de x_i y $f(j)$, podemos analizar el problema presentado e informarles a los Dai Li la secuencia de estrategias que les permitirá eliminar la mayor cantidad de enemigos empleando ataques de fisuras.

1.2 Análisis y ecuación de recurrencia

La resolución de un problema por medio de la programación dinámica implica reutilizar las soluciones a subproblemas más pequeños en subproblemas más grandes que los incluyan. En el contexto actual, el foco está puesto en maximizar la cantidad de enemigos eliminados dados n minutos. Esta variable n es crucial en el análisis del problema planteado puesto que si se tiene k minutos, con $k < n$, necesariamente la cantidad de enemigos eliminados será menor o igual a la solución en el minuto n , siendo igual en el caso de que no lleguen más enemigos entre k y n minutos. De esta forma, la cantidad de minutos que tiene el ataque repercute en el resultado final del combate. Por ejemplo, si $n = 0$, se puede afirmar que la cantidad de enemigos eliminados será también 0. Entonces, nuestros subproblemas estarán dados por la cantidad máxima de enemigos que se pueden eliminar en cada minuto $i \leq n$.

Sabiendo la forma de los subproblemas, debemos analizar cómo se componen para resolver subproblemas más grandes. Si queremos obtener la solución óptima en el minuto i , vamos a poder utilizar las soluciones parciales calculadas hasta entonces, pero no nos interesa si existen o no problemas más grandes. En cada minuto $i < n$ hay solamente dos estrategias posibles: atacar o cargar.

Atacar implica enfrentarse con el enemigo, derrotando $\min(x_i, f(j))$ soldados (con j siendo la cantidad de minutos desde el ataque anterior) y perdiendo la energía acumulada. En cambio, definimos **cargar** como la acción de decidir no atacar y acumular más energía para un ataque futuro.

Sin embargo, en el caso del minuto $i = n$, ¿tiene sentido cargar sabiendo que no van a llegar más enemigos en el futuro? No. Ésto se debe a que la cantidad de maestros Fuego que se podrá eliminar en ese minuto (no en total) será mayor o igual a 0, pero si cargamos energía, será definitivamente nula. Por lo tanto, en el último minuto conviene siempre atacar. Ahora bien, como establecimos antes, en el minuto $i \leq n$ no importa si $i = n$ o $i < n$, solamente debemos calcular el óptimo actual. En base al análisis previamente presentado, siempre va a ser mejor atacar a cargar, más allá de que en la solución final (problema mayor) se lleve a cabo la estrategia opuesta debido a que eso esté contemplado en el óptimo del minuto n .

Si en el minuto i los Dai Li atacan, la cantidad de enemigos eliminados en ese instante será $\min(f(j), x_i)$. El valor de x_i es conocido, pero la energía acumulada ($f(j)$) por la policía secreta de la ciudad depende de los minutos que pasaron desde el último ataque. De esta manera, tenemos una segunda variable involucrada en el problema: j . Si el último ataque fue realizado hace un minuto, actualmente se podrá eliminar $\min(f(1), x_i)$ soldados y la cantidad de enemigos eliminados acumulada será la suma entre este valor y el correspondiente en el ataque anterior.

¿Qué sucede si el óptimo hace dos minutos es mayor que en el minuto anterior o su suma con $\min(f(2), x_i)$ lo es? Como queremos maximizar el resultado final, claramente nos conviene haber atacado hace dos minutos, lo cual también indica que en el minuto $i - 1$ se cargó energía. Tenemos varias opciones para el ataque anterior, más precisamente $1 \leq j \leq i$, pero utilizaremos aquel que nos lleve a la mejor solución. Entonces, el óptimo para el minuto i será la suma entre $\min(f(j), x_i)$ y el óptimo en el minuto $i - j$.

Sabiendo la forma de los subproblemas y la manera en que éstos se combinan, podemos plantear la **ecuación de recurrencia** para el minuto i :

$$OPT[i] = \max(\min(f(j), x_i) + OPT[i - j] \mid j \in [1; i])$$

Como caso base, tenemos que en el minuto 0 se eliminan 0 enemigos.

Encontrada la ecuación de recurrencia, procedemos a aplicarla iterativamente de manera bottom up, construyendo las soluciones a los subproblemas de $i < n$ hasta llegar a la solución del problema original con $i = n$. En cada minuto utilizamos las soluciones a subproblemas menores. La técnica explicada es justamente programación dinámica. Empleamos **memoization** guardando los resultados calculados previamente en un arreglo. El procedimiento explicado nos permite realizar una exploración implícita del espacio de soluciones. La solución final será óptima porque en el minuto n elegimos haber atacado hace j minutos, donde j maximiza la ecuación de recurrencia.

Como conclusión, el uso de esta ecuación de recurrencia en nuestra implementación nos permite determinar la cantidad máxima de enemigos que se

pueden atacar. En cada minuto calculamos el máximo número de adversarios eliminados si se decide atacar en ese instante. Este valor está determinado por el tiempo entre éste y el ataque anterior. Al quedarnos con un j que maximice la suma final de enemigos derrotados en el minuto i , nos aseguramos de obtener una solución óptima a ese subproblema. Luego, en el último minuto del combate, utilizaremos las soluciones a estos subproblemas de forma tal que tendremos en cuenta el ataque anterior que ocurrió en el minuto $k = n - j$, donde $OPT[k] + \min(f(j), x_n)$ maximiza la cantidad de enemigos eliminados en total. A su vez, el $OPT[k]$ tiene lo mismo en consideración.

Guardar los óptimos en un arreglo de soluciones parciales para cada minuto nos facilita reconstruir la estrategia de ataque óptima que permite obtener el resultado para $OPT[n]$. Sabiendo el valor de la cantidad de enemigos que lleguen en el minuto n , x_n , podemos comparar resultados parciales con $OPT[n]$ para obtener j . Es decir, como ya determinamos que en el minuto n vamos a atacar, j va a corresponder al resultado que cumpla con $OPT(n) = OPT(k) + \min(f(j), x_n)$, siendo k el minuto en que previamente se realizó un ataque ($k = n - j$). Entre k y n , la estrategia empleada es recargar fuerzas.

Repetimos el procedimiento para k , hasta llegar al minuto 0.

2 Complejidad algorítmica

2.1 Complejidad lectura de archivos

Antes de comenzar el algoritmo, tenemos que generar las listas de elementos sobre las cuales éste va a operar. Para esto tenemos la siguiente porción de código:

```

5 def generarTestDe(archivo):
6     """
7     Recibe un archivo, lo abre, lee y devuelve los datos 'n', 'x' y 'f'.
8     """
9     x = []
10    f = []
11    with open(archivo, "r") as file:
12        n = None
13        elem_actual = 1
14        for i, line in enumerate(file):
15            line = line.strip()
16            if line.startswith("#"):
17                continue
18            if not n:
19                n = int(line)
20                continue
21            if elem_actual <= n:
22                x.append(int(line))
23                elem_actual += 1

```

```

24         else:
25             f.append(int(line))
26
27     return n, x, f

```

La función lee la línea que contiene la cantidad de valores que van a tener ambas listas. Una vez hecho eso, lee n líneas para almacenar los distintos valores de x_i y luego lee otras n líneas para tener los valores de $f(j)$. Esto tiene una complejidad temporal $O(2 \cdot n)$ que, despreciando la constante, resulta $O(n)$.

2.2 Complejidad algoritmo

```

25 def eliminar_enemigos(n,x,f):
26     """
27     Algoritmo de programación dinámica para determinar la cantidad máxima de
28     enemigos que pueden ser derrotados. Utiliza obtener_secuencia_estrategias()
29     para reconstruir las estrategias de ataque empleadas.
30
31     Recibe:  $n \geq 0$  y las listas  $x$  y  $f$ , cuyo tamaño es  $n$ .  $f$  toma valores
32     monótonos crecientes.
33     Devuelve: cantidad de enemigos eliminados y secuencia de estrategias
34     """
35     enemigos_eliminados = [0] * (n + 1)
36
37     for minuto_actual in range(1, n + 1):
38         max_enemigoseliminables = min(f[0], x[minuto_actual-1])
39         for minutos_desde_ultimo_ataque in range(minuto_actual):
40             enemigos_actuales = min(f[minutos_desde_ultimo_ataque], x[minuto_actual-1])
41             offset = minuto_actual-minutos_desde_ultimo_ataque-1
42             enemigos_ataque_anterior = enemigos_eliminados[offset]
43
44             if enemigos_ataque_anterior + enemigos_actuales > max_enemigoseliminables:
45                 max_enemigoseliminables = enemigos_ataque_anterior + enemigos_actuales
46
47         enemigos_eliminados[minuto_actual] = max_enemigoseliminables
48
49     max_enemigos = enemigos_eliminados[-1]
50     secuencia = obtener_secuencia_estrategias(x, f, enemigos_eliminados, n)
51     secuencia.reverse()
52     return (max_enemigos, secuencia)

```

El algoritmo empieza creando una lista de tamaño $n + 1$. Según la documentación oficial, esto conlleva $\mathcal{O}(n)$ ya que se realiza n veces (en realidad, $n + 1$, pero el 1 es una constante) una operación de tiempo constante $\mathcal{O}(1)$.

Luego, en la línea 37 comienza un ciclo `for` que recorre todos los valores de n . En la línea 39 comienza un nuevo ciclo `for`, el cual va desde 0 hasta el

minuto actual i . Esto significa que, en el peor de los casos, este ciclo va a iterar hasta n . Dentro del ciclo, todas las operaciones son $\mathcal{O}(1)$, es decir, constantes.

Al tener dos ciclos anidados que realizan la cantidad de iteraciones mencionadas, podemos afirmar que la complejidad algorítmica de las líneas 37 a 47 es $\mathcal{O}(n^2)$.

Luego, en la línea 50 se ejecuta la función `obtener_secuencia_estrategias`, la cual analizamos en Complejidad reconstrucción de la solución. Sin embargo, podemos adelantar que su complejidad será también cuadrática.

Finalmente, en la línea 51 se ejecuta el método `reverse()`, el cual tiene complejidad $\mathcal{O}(n)$

Entonces, el algoritmo de programación dinámica tiene una complejidad

$$\mathcal{T}(n) = 2 \cdot \mathcal{O}(n^2) + \mathcal{O}(n) = \mathcal{O}(n^2)$$

2.3 Complejidad reconstrucción de la solución

```

54 def obtener_secuencia_estrategias(x, f, enemigos_eliminados, minuto_actual):
55     """
56     Reconstruye la secuencia de estrategias usada para eliminar la mayor
57     cantidad de enemigos.
58     Empieza por el último minuto de combate sabiendo que la estrategia es
59     'atacar'. Comparando valores del arreglo de óptimos 'enemigos_eliminados',
60     busca el minuto en el que se realizó el ataque anterior. Mientras que no
61     lo encuentra, la estrategia es 'cargar'. Repite hasta llegar al minuto 0.
62     """
63     secuencia = []
64     while minuto_actual > 0:
65
66         secuencia.append(ATACAR)
67
68         for minutos_desde_ultimo_ataque in range(minuto_actual):
69
70             offsetMins = minuto_actual-minutos_desde_ultimo_ataque-1
71             enemigos_ataque_anterior = enemigos_eliminados[offsetMins]
72
73             cantReales = min(f[minutos_desde_ultimo_ataque], x[minuto_actual-1])
74             enemigos_actuales = cantReales
75
76             enemigosDerrotados = enemigos_ataque_anterior + enemigos_actuales
77             esIgual = enemigosDerrotados == enemigos_eliminados[minuto_actual]
78             if esIgual:
79                 minuto_actual = minuto_actual-minutos_desde_ultimo_ataque-1
80                 break
81             else:
82                 secuencia.append(CARGAR)
83 
```

84 `return` `secuencia`

La reconstrucción de la secuencia estratégica empieza desde el último minuto, hasta 0. Vemos que en la línea 64 tenemos un ciclo `while`, el cual tiene dentro un ciclo `for`. Dentro del `for` todas las operaciones son de complejidad $\mathcal{O}(1)$.

En el peor de los casos, podemos pensar a estos dos ciclos como dos ciclos anidados que iteran desde 0 hasta n . Por esto, decimos que la reconstrucción va a tener una complejidad de $\mathcal{O}(n^2)$.

2.4 Efecto de las variables sobre el algoritmo

La complejidad obtenida es tenida en cuenta para el peor caso posible. Sin embargo, existe la posibilidad de que se ejecute en $\mathcal{O}(n)$ si se recibe un set de datos con determinadas características.

Este es el caso cuando todos los datos de x_i son menores al resultado de $f[0]$ que se corresponde con un minuto de diferencia con el ataque anterior, es decir, $f(1)$. Esto se debe a que el resultado será predecible ya que se podría derrotar al 100% de enemigos en todos los ataques sin necesidad de cargar fuerzas.

La comprobación de si el conjunto de datos de entrada cumple esta condición es realizada antes de ejecutar el algoritmo propiamente dicho. Es decir, primero utilizamos la función `esOptimizable(n, x, f)` que hace la verificación en tiempo lineal. Si efectivamente cumple el requisito, `eliminar_enemigos_optimizado(n, x)` resuelve el problema planteado en tiempo $\mathcal{O}(n)$ sumando la totalidad de enemigos y estableciendo una secuencia en la que siempre se ataca. Si bien este algoritmo no es de programación dinámica, creemos que es fundamental tenerlo en cuenta especialmente con sets de datos muy grandes donde la complejidad lineal por sobre la cuadrática puede hacer una gran diferencia en el tiempo de ejecución. Por el contrario, si no se puede optimizar, entonces ejecutamos nuestro algoritmo de programación dinámica. En este caso, realizar la comprobación no afecta la complejidad resultante, sigue siendo $\mathcal{O}(n^2)$.

```
4 def esOptimizable(n, x, f):
5     """
6     Indica si, dado el conjunto de datos de entrada, se puede
7     utilizar la versión optimizada del algoritmo.
8     Se debe cumplir que cada  $x_i$  sea menor que  $f[0] = f(1)$ 
9     """
10    for minuto_actual in range(n):
11        if x[minuto_actual] > f[0]:
12            return False
13    return True
14
15 def eliminar_enemigos_optimizado(n, x):
16     """
17     Devuelve el resultado del algoritmo si el mismo esOptimizable().
18     Se eliminan todos los enemigos y se ataca en cada minuto.
```



```

19         """
20         enemigos_eliminados = x
21         max_enemigos = sum(enemigos_eliminados)
22         secuencia = [ATACAR] * n
23         return (max_enemigos, secuencia)

```

3 Análisis de optimalidad ante la variabilidad de x_i y $f(j)$

Para comprobar la optimalidad de nuestro algoritmo, realizamos múltiples pruebas variando los valores de x_i y $f(j)$. En Ejemplos de ejecución se encuentra la explicación detallada de los casos de prueba. En general usamos $n = 5$ para poder calcular de antemano el resultado óptimo esperado y posteriormente compararlo con el obtenido por nuestro algoritmo. En cada caso ambos resultados coincidieron.

Como mencionamos anteriormente, nuestra implementación hace una exploración implícita de todo el espacio de soluciones. Esto se ve reflejado tanto en el código como en la ecuación de recurrencia. Para buscar el par de valores que maximice la cantidad de enemigos derrotados, iteramos por todos los valores posibles de $f(j)$ dado un x_i , teniendo en cuenta que $j \leq i$.

Esto implica que no hay combinación de x_i y $f(j)$ que no sea explorada por el algoritmo. Es decir, mientras que se cumplan las condiciones iniciales del problema (misma cantidad de valores para x_i y $f(j)$), el algoritmo va a llegar a la solución óptima. Como pueden existir múltiples secuencias de estrategias que impliquen eliminar la cantidad máxima de enemigos, nuestro algoritmo solo devolverá una, dada por la función de reconstrucción de la solución. La función `es_secuencia_correcta` nos permite validarla al ejecutar los tests.

```

86 def es_secuencia_correcta(x, f, cantidad_enemigos, secuencia):
87     """
88     Recibe un conjunto de datos 'x' y 'f', y el resultado obtenido
89     al aplicar el algoritmo de programación dinámica,
90     'cantidad_enemigos' y 'secuencia'.
91     Comprueba que siguiendo la secuencia de estrategias recibida,
92     se puedan eliminar 'cantidad_enemigos'.
93     """
94     minutos_desde_ultimo_ataque = 0
95     tropas_eliminadas = 0
96     for minuto_actual, estrategia in enumerate(secuencia):
97
98         if estrategia == ATACAR:
99
100             tropas_eliminadas += min(x[minuto_actual], f[minutos_desde_ultimo_ataque])
101             minutos_desde_ultimo_ataque = 0
102         else:

```

```

103         minutos_desde_ultimo_ataque += 1
104     return tropas_eliminadas == cantidad_enemigos

```

A continuación procedemos a explicar el comportamiento de nuestro algoritmo con un ejemplo sencillo. Dados los siguientes datos de entrada

$n = 5$
 $x = [109, 180, 926, 100, 877]$
 $f = [119, 300, 800, 888, 889]$

Queremos maximizar la cantidad de enemigos eliminados. Para ello, hacemos uso de la ecuación de recurrencia planteada anteriormente. En el minuto $i = 0$, la cantidad de enemigos eliminados es 0.

1. minuto actual = 1 \rightarrow La única opción es atacar, eliminando $\min(x_1, f(1))$. Luego, $OPT[1] = 109$.
2. minuto actual = 2 \rightarrow Tenemos 2 opciones:
 - Atacar en el minuto 1 y en el 2 $\rightarrow OPT[1] + \min(x_2, f(1)) = 109 + 119 = 228$
 - Cargar en el minuto 1 y atacar en el 2 $\rightarrow OPT[0] + \min(x_2, f(2)) = 0 + 180 = 180$
 - Nos quedamos con el valor máximo $\rightarrow OPT[2] = 228$
3. minuto actual = 3 \rightarrow Además de atacar en este minuto, podemos haber atacado hace:
 - 1 minuto $\rightarrow OPT[3 - 1] + \min(x_3, f(1)) = 228 + 119 = 347$
 - 2 minutos $\rightarrow OPT[3 - 2] + \min(x_3, f(2)) = 109 + 300 = 409$
 - 3 minutos $\rightarrow OPT[3 - 3] + \min(x_3, f(3)) = 0 + 800 = 800$
 - Nos quedamos con el valor máximo $\rightarrow OPT[3] = 800$
4. minuto actual = 4 \rightarrow El último ataque pudo haber ocurrido hace:
 - 1 minuto $\rightarrow OPT[4 - 1] + \min(x_4, f(1)) = 800 + 100 = 900$
 - 2 minutos $\rightarrow OPT[4 - 2] + \min(x_4, f(2)) = 228 + 100 = 328$
 - 3 minutos $\rightarrow OPT[4 - 3] + \min(x_4, f(3)) = 109 + 100 = 209$
 - 4 minutos $\rightarrow OPT[4 - 4] + \min(x_4, f(4)) = 0 + 100 = 100$
 - Nos quedamos con el valor máximo $\rightarrow OPT[4] = 900$
5. minuto actual = 5 \rightarrow Tenemos 5 opciones para el ataque anterior. Éste pudo suceder hace:
 - 1 minuto $\rightarrow OPT[5 - 1] + \min(x_5, f(1)) = 900 + 119 = 1019$
 - 2 minutos $\rightarrow OPT[5 - 2] + \min(x_5, f(2)) = 800 + 300 = 1100$
 - 3 minutos $\rightarrow OPT[5 - 3] + \min(x_5, f(3)) = 228 + 800 = 1028$

- 4 minutos $\rightarrow OPT[5 - 4] + \min(x_5, f(4)) = 109 + 877 = 986$
- 5 minutos $\rightarrow OPT[5 - 5] + \min(x_5, f(5)) = 0 + 877 = 877$
- Nos quedamos con el valor máximo $\rightarrow OPT[5] = 1100$

Obtuvimos el siguiente arreglo de óptimos para cada minuto del combate:

$$OPT = [0, 109, 228, 800, 900, 1100]$$

Podemos concluir que la cantidad máxima de enemigos eliminados es 1100. Como se puede observar en el seguimiento realizado, exploramos para cada minuto la opción de haber atacado hace 1, ..., j minutos. Para ello utilizamos las soluciones a subproblemas más pequeños. Nos quedamos con el valor que maximiza la ecuación de recurrencia. Éste es nuestro óptimo local para el minuto dado. Cuando llegamos a $i = n$ realizamos el mismo procedimiento, obteniendo el óptimo global para el algoritmo. De esta forma, exploramos todas las posibles combinaciones de $i \leq n$ y j . Ésto nos permite obtener un resultado óptimo siempre, a pesar de variar los valores de x_i y $f(j)$.

Para reconstruir la solución, tomamos el camino inverso. Empezamos con el minuto n porque sabemos que al final siempre vamos a atacar. Variando el valor de j desde 0 (haber atacado hace 1 minuto) hasta el minuto actual - 1 (ataque anterior hace i minutos), nos fijamos cuál es el que permite obtener el óptimo dado. Como $j = 0$ no cumple, significa que en el minuto 4 la policía secreta recargó fuerzas. En cambio, en $n = 3$ se decidió atacar. Repetimos el procedimiento para ese minuto y concluimos que fue el primer ataque. Luego, la secuencia obtenida es: Cargar, Cargar, Atacar, Cargar, Atacar.

4 Ejemplos de ejecución

Se pueden encontrar en la carpeta `ejemplos_adicionales` del repositorio entregado algunos ejemplos de posibles ejecuciones creadas para corroborar la optimalidad del algoritmo planteado. Los sets con pocos datos fueron generados a mano con el objetivo de verificar casos de prueba específicos. En cambio, con los tests de volumen usamos datos aleatorios generados con la biblioteca `random`, respetando que `f` sea monótona creciente.

Además de los ejemplos brindados por la cátedra, se pensó en distintas perspectivas que podrían *comprometer* de alguna manera la solución del algoritmo. Algunos aspectos evaluados fueron:

- Momento en el que realiza el primer ataque:
 - `atacar_al_inicio`: El primer ataque es al inicio del combate
 - `atacar_a_la mitad`: El primer ataque es a la mitad del combate
 - `atacar_al_final`: El primer ataque es al final del combate
 - `atacar_siempre`: No conviene nunca reservar energía, ataca siempre
- Relación numérica entre x_i y $f(j)$

- `x_menor_a_f`: Todos los x_i son menores a todos los $f(j)$
- `x_mayor_a_f`: Todos los x_i son mayores a todos los $f(j)$
- `x_igual_a_f`: Todos los x_i son iguales a todos los $f(j)$ (con $i == j$)
- `igual_xi_menor_a_f0`: Todos los x_i son iguales entre sí y menores a $f(0)$
- `igual_xi_mayor_a_f0`: Todos los x_i son iguales entre sí y mayores a $f(0)$
- Diferencia numérica entre x_i y x_{i+1} , y $f(j)$ y $f(j+1)$
 - `dif_x_cero`: La diferencia numérica entre cada x_i es nula
 - `dif_x_chica`: La diferencia numérica entre cada x_i es de 10^{-i}
 - `dif_x_grande`: La diferencia numérica entre cada x_i es de 10^i
 - `dif_f_chica`: La diferencia numérica entre cada $f(j)$ es de 10^{-j}
 - `dif_f_grande`: La diferencia numérica entre cada $f(j)$ es de 10^j
- Ordenamiento de x_i
 - `xi_descendente`: Los x_i están ordenados de manera descendente
 - `xi_ascendente`: Los x_i están ordenados de manera ascendente
 - Observación:** Los valores de $f(j)$ siempre estarán ordenados de manera ascendente por ser una función monótona creciente
- Volumen de ataques recibidos
 - `x_menor_a_f_volumen`: Todos los x_i son menores a $f(0)$ pero con una muestra de 100 combates

Los resultados de los ejemplos se podrán ejecutar en la terminal con los siguientes comandos:


- `python3 codigo/main.py`: Imprime todos los resultados de ejemplos adicionales y ejemplos de cátedra con su valor obtenido y esperado, incluyendo el tiempo de ejecución
- `python3 codigo/main.py ejemplos_adicionales/atacar_al_inicio.txt`: Si se quiere imprimir los resultados de un ejemplo particular
- `python3 codigo/main.py ejemplos_adicionales/atacar_al_inicio.txt --mostrarSecuencia`: Si se quiere imprimir los resultados de un ejemplo particular mostrando además la secuencia de estrategias implementadas

5 Mediciones de tiempo

Para corroborar la complejidad algorítmica de nuestra implementación, realizamos una serie de tests de volumen. Éstos tienen en cuenta el algoritmo de programación dinámica, sin la optimización explicada en Efecto de las variables sobre el algoritmo. A diferencia del TP1 y debido a la complejidad temporal del algoritmo, realizamos tests con una menor cantidad de casos. Para poder graficar y analizar el comportamiento de la implementación, realizamos dos corridas, una con alrededor de 3500 tests con un n entre 1 y 10000; y otra con alrededor 500 tests, con n entre 0 y 5000. El código que usamos para generar los tests se encuentra en el archivo `codigo/grafico_complejidad.py`. Empleamos la biblioteca `random` para generar valores aleatorios de x y f .

Observando los gráficos podemos entender mejor el comportamiento de nuestra implementación.


Con la primera corrida de tests obtuvimos:



Podemos ver que el gráfico tiene una forma cuasi parabólica, lo cual refleja el comportamiento cuadrático del algoritmo.

Además, podemos ver el rápido crecimiento que toman los valores. Por ejemplo, 2000 minutos de combate tardan alrededor de 500 mili-segundos y con 4000 el algoritmo tarda aproximadamente 2000 mili-segundos. Vemos que al duplicar el tamaño de la entrada, el tiempo de ejecución no se duplica, sino que se cuadruplica.

La segunda corrida de tests tuvo resultados análogos:



Al igual que el otro gráfico, este también tiene una forma parabólica. Podemos observar que con 1000 minutos de combate tarda alrededor de 160 mili-segundos y con $n = 2000$ conlleva más de 600 mili-segundos.

Para comparar con el gráfico anterior, calculamos el tiempo de ejecución exacto para $n = 2000$ y $n = 4000$, donde n es la cantidad de minutos en la que llegan enemigos de la Nación del Fuego. Obtuvimos 658 y 2567 mili-segundos, respectivamente, verificando que el patrón establecido se repite.

Con esto concluimos que, a medida que aumenta el tamaño de entrada n (cantidad de minutos), el tiempo de ejecución del algoritmo crece a un ritmo cuadrático. Esto coincide con el análisis de complejidad previamente presentado, indicando un costo proporcional a n^2 .

6 Conclusión

A partir de un análisis detallado del problema planteado obtuvimos una ecuación de recurrencia que nos permite obtener la solución utilizando un algoritmo de programación dinámica. Como mencionamos previamente, esta solución es óptima.

Para el caso particular en que los enemigos atacantes son siempre menos que la capacidad de combate de la policía (sin necesidad de recargar fuerzas), realizamos una optimización que mejora la complejidad temporal a la hora de hallar la cantidad máxima de enemigos derrotados. Este caso fue descubierto gracias a las pruebas de ejecución implementadas. Como hemos mencionado, si bien esa optimización no respeta la definición de programación dinámica, se decidió agregar porque no afecta en sí el concepto principal del algoritmo ni

tampoco a la complejidad global. Se trata de una excepción que representa un caso ideal, y no el peor caso.

Por otro lado, quisiéramos mencionar que en un comienzo nuestra primera implementación del algoritmo consistió en una matriz de $n \times n$, conteniendo todas las combinaciones posibles de i y j (con i siendo el minuto actual y j el tiempo transcurrido desde el último ataque). Sin embargo, como $j \leq i$, había celdas que quedaban vacías o cuyo valor no nos interesaba. Fue entonces cuando observamos una similitud del problema actual y el **Problema del cambio** visto en clase y decidimos utilizar un enfoque similar. En lugar de usar una matriz, lo cual implicaba $O(n^2)$ de complejidad espacial en memoria, utilizamos un arreglo de óptimos para cada minuto i , que la reduce a $O(n)$. Como pudimos demostrar en la sección Análisis de optimalidad ante la variabilidad de x_i y $f(j)$, solo precisamos almacenar un arreglo de óptimos minuto a minuto.